Fundus Görüntülerinden Katarakt, Diyabetik Retinopati ve Glokom Sınıflandırması: Klasik Görüntü İşleme ve Derin Öğrenme Yaklaşımlarının Karşılaştırılması

Classification of Cataract, Diabetic Retinopathy and Glaucoma from Fundus Images: A Comparison of Classical Image Processing and Deep Learning Approaches

[Yazar adları ve sıralaması eklenecek (6 kişi)]

Fırat Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü, Elazığ, Türkiye

Medikal Görüntü İşleme dersi proje çalışması

ÖZET

Katarakt, diyabetik retinopati ve glokom, dünya genelinde önlenebilir görme kaybının başlıca nedenleri arasındadır ve renkli fundus fotoğrafları bu hastalıkların taranmasında yaygın olarak kullanılan, girişimsel olmayan bir görüntüleme yöntemidir. Bu çalışmada fundus görüntülerini normal, katarakt, diyabetik retinopati ve glokom olmak üzere dört sınıfa ayıran iki yaklaşım aynı veri bölmesi üzerinde karşılaştırılmaktadır. Herkese açık bir veri setinden her sınıf için 1007 görüntü seçilmiş ve aynı hastanın iki gözünün farklı kümelere düşmesini önleyen hasta düzeyinde bir bölme ile 2820 eğitim, 604 doğrulama ve 604 test görüntüsü elde edilmiştir. Tüm görüntülere ilgi bölgesi kırpma, yeşil kanal ayrıştırma, kontrast sınırlı uyarlamalı histogram eşitleme (CLAHE) ve median filtreden oluşan ortak bir ön işleme uygulanmıştır. Birinci yaklaşımda damar yoğunluğu, optik disk ve çukur/disk oranı, lezyon ve netlik ölçümlerinden oluşan öznitelikler destek vektör makineleri ve rastgele orman ile sınıflandırılmıştır. İkinci yaklaşımda ImageNet üzerinde önceden eğitilmiş EfficientNet-B0 modeli transfer öğrenme ile eğitilmiş ve kararları Grad-CAM ısı haritalarıyla görselleştirilmiştir. [Bulgular: iki yaklaşımın test doğruluğu, makro F1 değerleri ve en çok karışan sınıflar sonuçlar gelince eklenecek.] Ayrıca veri setinde sınıflar arasında kaynak ve çözünürlük farkları ile veri artırma yoluyla üretilmiş görüntü kopyaları tespit edilmiş ve bunların bildirilen başarıya olası etkisi tartışılmıştır.

Anahtar Kelimeler: Fundus görüntüsü, Katarakt, Diyabetik retinopati, Glokom, EfficientNet, Grad-CAM, Destek vektör makineleri

ABSTRACT

[İngilizce özet, Türkçe özet sonuçlarla birlikte kesinleşince yazılacak.]

Keywords: Fundus image, Cataract, Diabetic retinopathy, Glaucoma, EfficientNet, Grad-CAM, Support vector machines

1. GİRİŞ

Dünya Sağlık Örgütü verilerine göre dünyada en az 2,2 milyar kişide yakın ya da uzak görme bozukluğu bulunmakta ve bunların en az 1 milyarında görme bozukluğu önlenebilir olduğu hâlde önlenememiş ya da henüz giderilmemiştir [1]. Bu grupta uzak görme bozukluğunun önde gelen nedenleri arasında katarakt (94 milyon), glokom (7,7 milyon) ve diyabetik retinopati (3,9 milyon) yer almaktadır [1]. Küresel Hastalık Yükü çalışmasına göre 2020 yılında 50 yaş ve üzerindeki bireylerde körlüğün en sık nedeni 15,2 milyon vaka ile katarakt olmuş, bunu 3,6 milyon vaka ile glokom izlemiştir [2].

Bu hastalıkların yükünün önümüzdeki yıllarda artması beklenmektedir. Dünyada geri dönüşü olmayan körlüğün başlıca nedeni olan glokomun 2013 yılında 40-80 yaş arasındaki 64,3 milyon kişiyi etkilediği ve bu sayının 2040 yılında 111,8 milyona ulaşacağı öngörülmektedir [3]. Diyabetik retinopati, çalışma çağındaki yetişkinlerde önlenebilir körlüğün önde gelen nedenlerindendir; diyabetli bireylerde görülme

sıklığı %22,27 olarak hesaplanmış ve diyabetik retinopatili yetişkin sayısının 2020 yılındaki 103,12 milyondan 2045 yılında 160,50 milyona yükseleceği tahmin edilmiştir [4].

Renkli fundus fotoğrafları retinanın girişimsel olmayan bir yöntemle görüntülenmesini sağladığından bu hastalıkların taranmasında yaygın olarak kullanılmaktadır. Hastalıkların her biri fundus görüntüsünde farklı izler bırakır: diyabetik retinopatide mikroanevrizma, eksüda ve kanama gibi lezyonlar ortaya çıkar [5]; glokomda optik sinir başındaki çukurlaşma nedeniyle çukur/disk oranı (cup-to-disc ratio, CDR) artar [6], [7]; kataraktta ise göz merceğindeki bulanıklık retinanın görülebilirliğini azaltır ve belirgin kataraktı olan hastalarda fundusun daha net görüntülenebilmesi için farklı görüntüleme yöntemleri araştırılmıştır [8]. Kataraktın fundus fotoğrafına etkisi Gauss bulanıklığı ile benzetildiğinde derin öğrenmeye dayalı diyabetik retinopati tespitinin doğruluğu %97,0'dan orta düzeyde benzetilmiş kataraktta %62,8'e düşmektedir [9].

Tıbbi kaynakların yetersiz olduğu durumlarda görüntülerin elle incelenmesi zaman alıcıdır ve tanıyı geciktirebilir [10]. Bu nedenle fundus görüntülerinin otomatik analizine yönelik çok sayıda çalışma yapılmıştır. Klasik yaklaşımlar damar, optik disk ve lezyon gibi yapıları görüntü işleme teknikleriyle ölçerek yorumlanabilir öznitelikler üretir [6], [11]. Derin öğrenmeye dayalı sistemler ise büyük veri setlerinde yüksek duyarlılık ve özgüllük değerleri bildirmiştir [12], [13]; ancak bu modellerin kararlarına nasıl ulaştığı doğrudan görülemediğinden Grad-CAM gibi açıklanabilirlik yöntemleriyle desteklenmeleri gerekir [14].

Bu çalışmada renkli fundus görüntülerinin normal, katarakt, diyabetik retinopati ve glokom olmak üzere dört sınıfa ayrılması için iki yaklaşım aynı veri bölmesi ve aynı test kümesi üzerinde karşılaştırılmaktadır. Çalışmanın katkıları şunlardır: (i) herkese açık bir veri setinden dengeli ve hasta düzeyinde bölünmüş bir deney düzeni oluşturulması, veri setindeki kaynak farklılıklarının ve çoğaltılmış görüntülerin nicel olarak raporlanması; (ii) damar, optik disk, lezyon ve netlik ölçümlerine dayanan yorumlanabilir bir klasik sınıflandırma hattı; (iii) EfficientNet-B0 ile transfer öğrenmeye dayanan ve Grad-CAM ile açıklanan bir derin öğrenme modeli; (iv) iki yaklaşımın aynı test kümesinde karşılaştırılması ve sonuçların bir web arayüzünde sunulması.

Makalenin geri kalanı şöyle düzenlenmiştir: 2. bölümde ilgili çalışmalar, 3. bölümde veri seti, 4. bölümde yöntem, 5. bölümde bulgular, 6. bölümde tartışma ve 7. bölümde sonuçlar sunulmaktadır.

2. İLGİLİ ÇALIŞMALAR

Fundus görüntülerinin otomatik analizine yönelik ilk çalışmalar, hastalığa özgü yapıların klasik görüntü işleme yöntemleriyle bulunmasına dayanmaktadır. Walter vd. [11], sert eksüdaları yüksek gri düzey değişimlerinden yararlanarak bulmuş, sınırlarını morfolojik yeniden yapılandırma ile belirlemiş ve küçük bir görüntü veri tabanında %92,8 ortalama duyarlılık ile %92,4 ortalama kestirim değeri elde etmiştir. Cheng vd. [6], optik disk ve optik çukuru süperpiksel sınıflandırmasıyla bölütlemiş ve elde ettikleri çukur/disk oranıyla glokom taramasında iki veri setinde 0,800 ve 0,822 eğri altı alan (AUC) bildirmiştir. Damar yapılarının belirginleştirilmesinde çok ölçekli Frangi filtresi yaygın biçimde kullanılmaktadır [15]; Budai vd. [16] ise yüksek çözünürlüklü fundus görüntüleri için gürbüz bir damar bölütleme yöntemi önermiştir.

Derin öğrenmenin bu alanda kullanılmaya başlamasıyla birlikte büyük ölçekli veri setlerinde tek bir hastalığa odaklanan başarılı sistemler geliştirilmiştir. Gulshan vd. [12], 128 175 görüntüyle eğittikleri derin evrişimli sinir ağı (CNN) ile sevk gerektiren diyabetik retinopatiyi EyePACS-1 ve Messidor-2 veri setlerinde sırasıyla 0,991 ve 0,990 AUC ile saptamıştır. Pratt vd. [5], Kaggle'daki yaklaşık 80 000 görüntülük diyabetik retinopati veri setinde hastalık şiddetini sınıflandıran bir CNN ile 5000 doğrulama görüntüsünde %95 duyarlılık ve %75 doğruluk elde etmiştir. Li vd. [7], 48 116 fundus fotoğrafıyla

geliştirdikleri sistemle sevk gerektiren glokomatöz optik nöropatiyi 0,986 AUC ile saptamış ve yanlış negatif sonuçların en sık nedeninin yüksek miyopi başta olmak üzere eşlik eden göz hastalıkları olduğunu raporlamıştır. Junayed vd. [17], 1130 fundus görüntüsünü veri artırma ile 4746 görüntüye çıkararak eğittikleri CataractNet modeliyle katarakt tespitinde %99,13 ortalama doğruluk bildirmiştir.

Birden fazla hastalığı birlikte ele alan çalışmalar da bulunmaktadır. Ting vd. [13], 494 661 retina görüntüsü kullanarak geliştirdikleri sistemle sevk gerektiren diyabetik retinopati, olası glokom ve yaşa bağlı makula dejenerasyonu için sırasıyla 0,936, 0,942 ve 0,931 AUC elde etmiştir. Li vd. [10], 5000 hastanın iki gözüne ait 10 000 fundus görüntüsünden oluşan ve sekiz kategori içeren ODIR veri setini yayımlamış; yalnızca ağın ölçeğini büyütmenin çok hastalıklı sınıflandırmada iyi sonuç vermediğini ve hastalıkların özelliklerini birleştiren öznitelik füzyonu yöntemlerine gerek olduğunu belirtmiştir.

Bu çalışmada kullanılan dört sınıflı veri setiyle yapılan çalışmalar da son yıllarda artmıştır. IDRiD, HRF ve ODIR gibi kaynaklardan derlenmiş yaklaşık 4200 görüntülük dört sınıflı bir veri setinde Babaqi vd. [18], EfficientNet tabanlı transfer öğrenme ile %94, sıfırdan eğitilen bir CNN ile %84 doğruluk elde etmiştir. Alsohemi ve Dardouri [19], aynı Kaggle veri setinde ince ayar yapılmış EfficientNetB3 ile %95,12 doğruluk ve %95,00 F1 skoru bildirmiştir. Cutur ve İnan [20], görüntü dönüştürücü (Vision Transformer, ViT) tabanlı modellerle %98,1 test doğruluğuna ulaşmış; en iyi modeli ayrı tutulan %20'lik bir test kümesinde değerlendirdiklerinde doğruluk %94,21 olmuştur. Acevedo vd. [21] ise bu dört sınıfa diğer retina hastalıklarını ekleyerek oluşturdukları beş sınıflı bir veri setinde 11 katmanlı bir CNN ile tüm ölçütlerde %97 başarı bildirmiştir.

Bu çalışmalarda bildirilen yüksek doğruluk değerleri yorumlanırken dikkatli olunmalıdır. Örneğin Alsohemi ve Dardouri [19] ile Babaqi vd. [18], verinin görüntü düzeyinde mi yoksa hasta düzeyinde mi bölündüğünü belirtmemektedir. Aynı hastaya ya da aynı özgün görüntüye ait örneklerin hem eğitim hem test kümesinde bulunması test başarısını yapay olarak yükseltebilir. Nitekim Yagis vd. [22], beyin MR görüntülerinin sınıflandırılmasında kesit düzeyinde yapılan bölmenin test doğruluğunu veri setine göre %29 ile %55 arasında yanıltıcı biçimde artırdığını göstermiştir. Kapoor ve Narayanan [23] da veri sızıntısını makine öğrenmesine dayalı bilimdeki tekrarlanabilirlik sorunlarının başlıca nedenlerinden biri olarak ele almaktadır. İncelenen çalışmalar Tablo 1'de özetlenmiştir.

Tablo 1. Fundus görüntüleriyle göz hastalığı tespitine yönelik seçilmiş çalışmalar

Çalışma	Hastalık / sınıflar	Veri	Yöntem	Bildirilen sonuç
Walter vd. (2002) [11]	DR (sert eksüda)	Küçük bir görüntü veri tabanı	Morfolojik yeniden yapılandırma	Duyarlılık %92,8; kestirim değeri %92,4
Cheng vd. (2013) [6]	Glokom (CDR)	650 görüntü (bölütleme); 2 tarama veri seti	Süperpiksel sınıflandırma ile disk ve çukur bölütleme	AUC 0,800 ve 0,822
Gulshan vd. (2016) [12]	Sevk gerektiren DR	128 175 eğitim görüntüsü; EyePACS-1, Messidor-2	Derin CNN	AUC 0,991 ve 0,990
Pratt vd. (2016) [5]	DR şiddeti	Kaggle DR, yaklaşık 80 000 görüntü	CNN + veri artırma	Duyarlılık %95; doğruluk %75
Ting vd. (2017) [13]	DR, olası glokom, YBMD	494 661 görüntü	Derin öğrenme sistemi	AUC 0,936 / 0,942 / 0,931
Li vd. (2018) [7]	Glokomatöz optik nöropati	48 116 görüntü	Derin öğrenme	AUC 0,986; duyarlılık %95,6; özgüllük %92,0
Li vd. (2021) [10]	8 kategori	ODIR: 5000 hasta, 10 000 görüntü	Çeşitli derin ağlarla kıyaslama	Ölçek artışı tek başına yetersiz
Junayed vd. (2021) [17]	Katarakt / katarakt dışı	1130 görüntü (artırma ile 4746)	CataractNet (CNN)	Doğruluk %99,13

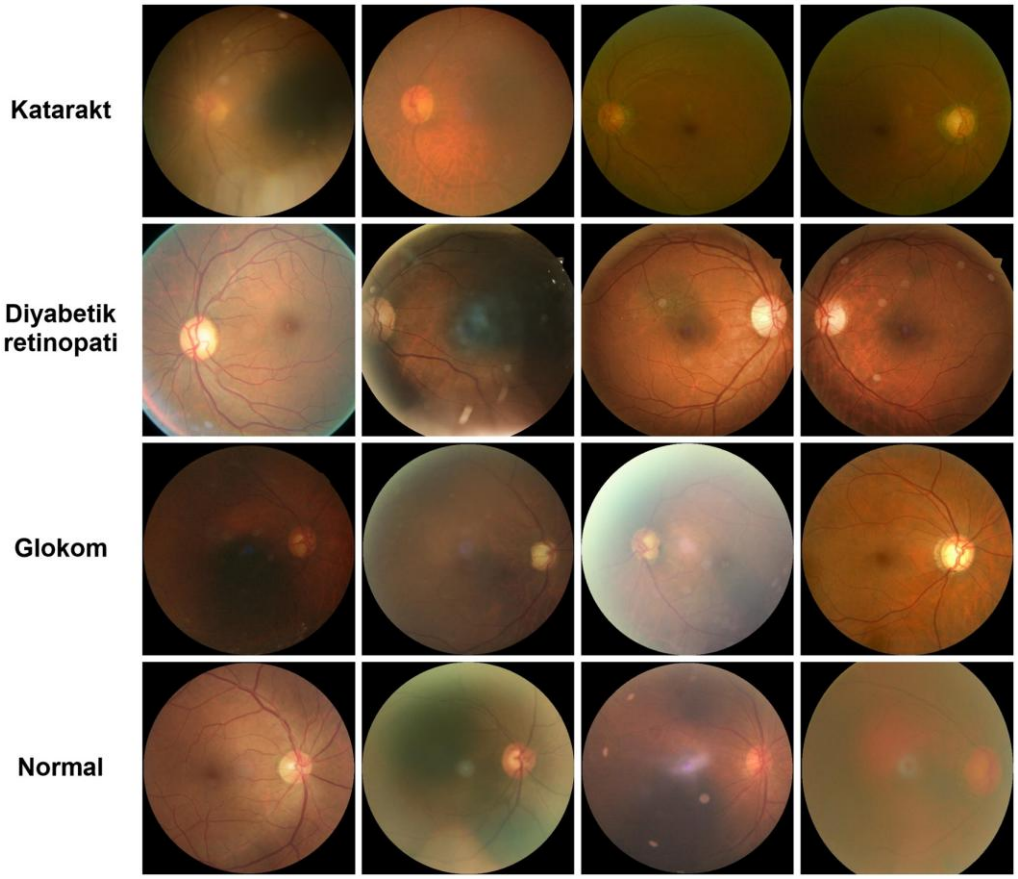
Çalışma	Hastalık / sınıflar	Veri	Yöntem	Bildirilen sonuç
Babaqi vd. (2023) [18]	Normal, katarakt, DR, glokom	Yaklaşık 4200 görüntü (IDRiD, HRF, ODIR vb.)	EfficientNet (transfer öğrenme); CNN	Doğruluk %94; CNN %84
Alsohemi ve Dardouri (2025) [19]	Normal, katarakt, DR, glokom	Kaggle, 4217 görüntü	EfficientNetB3 (transfer öğrenme)	Doğruluk %95,12; F1 %95,00
Cutur ve İnan (2025) [20]	Normal, katarakt, DR, glokom	Kaggle, 4217 görüntü	ViT (transfer öğrenme)	Doğruluk %98,1; ayrı test kümesinde %94,21
Acevedo vd. (2025) [21]	5 sınıf (dört sınıf + diğer retina hastalıkları)	5 sınıflı fundus veri seti	11 katmanlı CNN	Tüm ölçütlerde %97

DR: diyabetik retinopati; CDR: çukur/disk oranı; YBMD: yaşa bağlı makula dejenerasyonu; AUC: ROC eğrisi altında kalan alan; ViT: görüntü dönüştürücü.

3. VERİ SETİ

3.1. Kaynak ve İçerik

Çalışmada Kaggle platformunda herkese açık olarak paylaşılan *eye_diseases_classification* veri seti kullanılmıştır [24]. Veri seti normal, katarakt, diyabetik retinopati ve glokom sınıflarına ait toplam 4217 renkli fundus görüntüsü içermektedir (Tablo 2). Veri setinin açıklamasına göre görüntüler IDRiD [25], ODIR [10] ve HRF [16] gibi farklı açık kaynaklardan derlenmiştir. Görüntüler yalnızca sınıf klasörlerine ayrılmış olup hasta yaşı, cinsiyeti ya da hastalık evresi gibi ek bilgi içermemektedir. Veri tabanı Open Database lisansıyla, görüntülerin içeriği ise özgün yazarlarının haklarıyla paylaşılmaktadır [24]. Her sınıftan örnek görüntüler Şekil 1'de verilmiştir.



Şekil 1. Veri setindeki dört sınıftan örnek fundus görüntüleri. Görüntüler renk, aydınlatma ve netlik bakımından belirgin farklılıklar göstermektedir.

Tablo 2. Sınıflara göre görüntü sayıları

Sınıf	Ham veri	Kopya temizliği sonrası	Dengeleme sonrası
Katarakt	1038	1036	1007
Diyabetik retinopati	1098	1098	1007
Glokom	1007	1007	1007
Normal	1074	1074	1007
Toplam	**4217**	**4215**	**4028**

3.2. Veri Setinin Heterojenliği

Dosya adları ve görüntü boyutları incelendiğinde sınıfların farklı kaynaklardan geldiği ve görüntü özelliklerinin sınıfa göre belirgin biçimde değiştiği görülmüştür (Tablo 3). Seçilen diyabetik retinopati görüntülerinin tamamı 512×512 piksel boyutunda ve `.jpeg` uzantılıdır; normal sınıfındaki görüntülerin tamamı da 512×512 piksel boyutunda ve `.jpg` uzantılıdır. Her iki sınıfta da dosya adları hasta numarasını ve göz tarafını içermektedir (ör. `10042_right.jpeg`, `1228_left.jpg`). Katarakt ve glokom sınıfları ise üç farklı gruptan oluşmaktadır: aynı biçimde adlandırılmış 512×512 piksellik görüntüler, 1848×1224 ile 2592×1728 piksel arasında değişen yüksek çözünürlüklü `.png` görüntüler ve adları `_N_NNNNNNN.jpg` kalıbında olan 256×256 piksellik görüntüler. Bu durum, bir modelin hastalık bulguları yerine görüntünün kaynağına ilişkin özellikleri (çözünürlük, sıkıştırma, renk dengesi) öğrenmesi riskini doğurmaktadır [26]; konu 6. bölümde ayrıca tartışılmıştır.

Tablo 3. Seçilen 4028 görüntünün sınıf, çözünürlük ve dosya biçimine göre dağılımı

Sınıf	256×256 (.jpg)	512×512 (.jpg)	512×512 (.jpeg)	Yüksek çözünürlük (.png)*	Toplam
Katarakt	623	288	0	96	1007
Diyabetik retinopati	0	0	1007	0	1007
Glokom	600	306	0	101	1007
Normal	0	1007	0	0	1007

* 1848×1224, 2464×1632 ve 2592×1728 piksel boyutlarındaki görüntüler.

3.3. Veri Temizleme ve Dengeleme

Tüm görüntüler OpenCV ile açılarak bozuk dosya denetiminden geçirilmiş, okunamayan dosyaya rastlanmamıştır. Aynı içeriğe sahip görüntüleri bulmak için her dosyanın MD5 özeti hesaplanmıştır. Sınıfların kendi içinde kopya görüntü bulunmazken iki görüntünün (`625_left.jpg` ve `1415_right.jpg`) hem katarakt hem glokom klasöründe yer aldığı görülmüştür. ODIR veri setinde tanılar çok hastalıklı olarak verilebildiğinden [10] bu görüntülerin her iki hastalığı birlikte taşıması olasıdır; tek etiketli sınıflandırmada belirsizlik yaratmamaları için katarakt sınıfından çıkarılmışlardır (1038 → 1036). Ardından sınıf dengesizliğinin modelleri çoğunluk sınıfına yöneltmesini önlemek amacıyla en küçük sınıf olan glokomun örnek sayısı esas alınmış ve her sınıftan rastgele (tohum = 42) 1007 görüntü seçilerek toplam 4028 görüntülük dengeli bir veri seti oluşturulmuştur (Tablo 2).

3.4. Hasta Düzeyinde Bölme

Veri setindeki birçok hasta için sol ve sağ göze ait iki ayrı görüntü bulunmaktadır. Aynı hastanın iki gözü renk, aydınlatma ve damar yapısı bakımından birbirine benzediğinden bu görüntülerin eğitim ve test kümelerine ayrı ayrı düşmesi bir tür veri sızıntısıdır ve test başarısını olduğundan yüksek gösterebilir [22], [23]. Nitekim görüntü düzeyinde rastgele yapılan bölmede test kümesindeki 604 görüntünün 219'unda (%36,3) aynı hastanın diğer gözünün eğitim kümesinde bulunduğu belirlenmiştir. Bu nedenle

bölme hasta düzeyinde yapılmıştır: hasta kimliği dosya adındaki numaradan türetilmiş ve bir hastanın tüm görüntüleri yalnızca bir kümeye atanmıştır. Hastalar rastgele sıralandıktan sonra (tohum = 48) her hasta, sınıf hedeflerine göre en çok ihtiyaç duyulan kümeye açgözlü (greedy) bir yöntemle yerleştirilmiş ve her sınıf için tam olarak 705 eğitim (%70), 151 doğrulama (%15) ve 151 test (%15) görüntüsü elde edilmiştir (Tablo 4). Bu bölmede kümeler arasında ortak hasta kimliği bulunmamaktadır. Eğitim kümesi modellerin öğrenmesinde, doğrulama kümesi erken durdurma ve hiperparametre seçiminde, test kümesi ise iki yaklaşımın tarafsız karşılaştırmasında kullanılmaktadır.

Tablo 4. Hasta düzeyinde bölme sonrası görüntü sayıları

Sınıf	Eğitim	Doğrulama	Test	Toplam
Katarakt	705	151	151	1007
Diyabetik retinopati	705	151	151	1007
Glokom	705	151	151	1007
Normal	705	151	151	1007
Toplam	2820	604	604	4028
Hasta kimliği sayısı*	2059	443	439	2941

* Hasta kimliği dosya adından türetilmiştir; adında hasta bilgisi bulunmayan her dosya ayrı bir kimlik olarak sayılmıştır.

3.5. Veri Artırma ile Üretilmiş Görüntüler

256×256 piksel boyutundaki 1223 görüntünün (katarakt 623, glokom 600) adları `_N_NNNNNNN.jpg` kalıbındadır. Bu kalıp, Keras kütüphanesinin veri artırma sırasında üretilen görüntüleri diske kaydederken kullandığı "önek_sıra_rastgele sayı" adlandırmasıyla örtüşmektedir: önek boş bırakıldığında ad alt çizgiyle başlar, ilk sayı özgün görüntünün sıra numarasını, ikinci sayı ise 10^7'den küçük rastgele bir tamsayıyı gösterir [27]. Gerçekten de katarakt sınıfındaki 623 dosya yalnızca 397 farklı sıra numarası (0-400), glokom sınıfındaki 600 dosya ise 407 farklı sıra numarası (0-406) içermektedir ve birçok sıra numarası iki ya da üç dosyada yinelenmektedir. Görsel incelemede bu görüntülerin önemli bir kısmında dairesel olması gereken fundus alanının elips biçiminde basıklaştığı ve bazı görüntülerin birbirinin döndürülmüş hâli olduğu görülmüştür. Bu bulgular, söz konusu görüntülerin daha az sayıda özgün görüntüden veri artırma ile üretildiğini göstermektedir. Buna göre seçilen görüntüler arasında katarakt sınıfı için en fazla 781, glokom sınıfı için en fazla 814 özgün görüntü bulunmaktadır. Mevcut bölmede bu dosyalar ayrı hasta kimlikleri olarak ele alındığından aynı özgün görüntünün kopyaları farklı kümelere düşebilmektedir; bunun etkisi 6. bölümde ele alınmıştır.

4. YÖNTEM

4.1. Genel Yaklaşım

Önerilen sistem üç aşamadan oluşmaktadır: (i) tüm görüntülere uygulanan ortak ön işleme, (ii) iki ayrı sınıflandırma yaklaşımı, yani el ile tasarlanmış öznitelikler ile klasik makine öğrenmesi ve EfficientNet-B0 ile derin öğrenme, (iii) iki yaklaşımın aynı test kümesinde değerlendirilmesi ve sonuçların bir web arayüzünde sunulması. [Sistemin genel akış şeması eklenecek.]

4.2. Ön İşleme

Ön işleme hattı altı adımdan oluşmaktadır (Şekil 2):

(1) İlgi bölgesi kırpma: Görüntü gri tona çevrilmiş, yoğunluğu 10'dan büyük pikseller retina alanı olarak kabul edilmiş ve bu alanı çevreleyen en küçük dikdörtgen kırpılmıştır. Köşelerde kalan artıkları temizlemek için kırpılan görüntünün merkezine yerleştirilen ve yarıçapı kısa kenarın yarısına eşit olan dairesel bir maske uygulanmıştır.

(2) Boyutlandırma: Farklı çözünürlükteki görüntüler alan ortalaması (INTER_AREA) enterpolasyonu ile 512×512 piksele getirilmiştir.

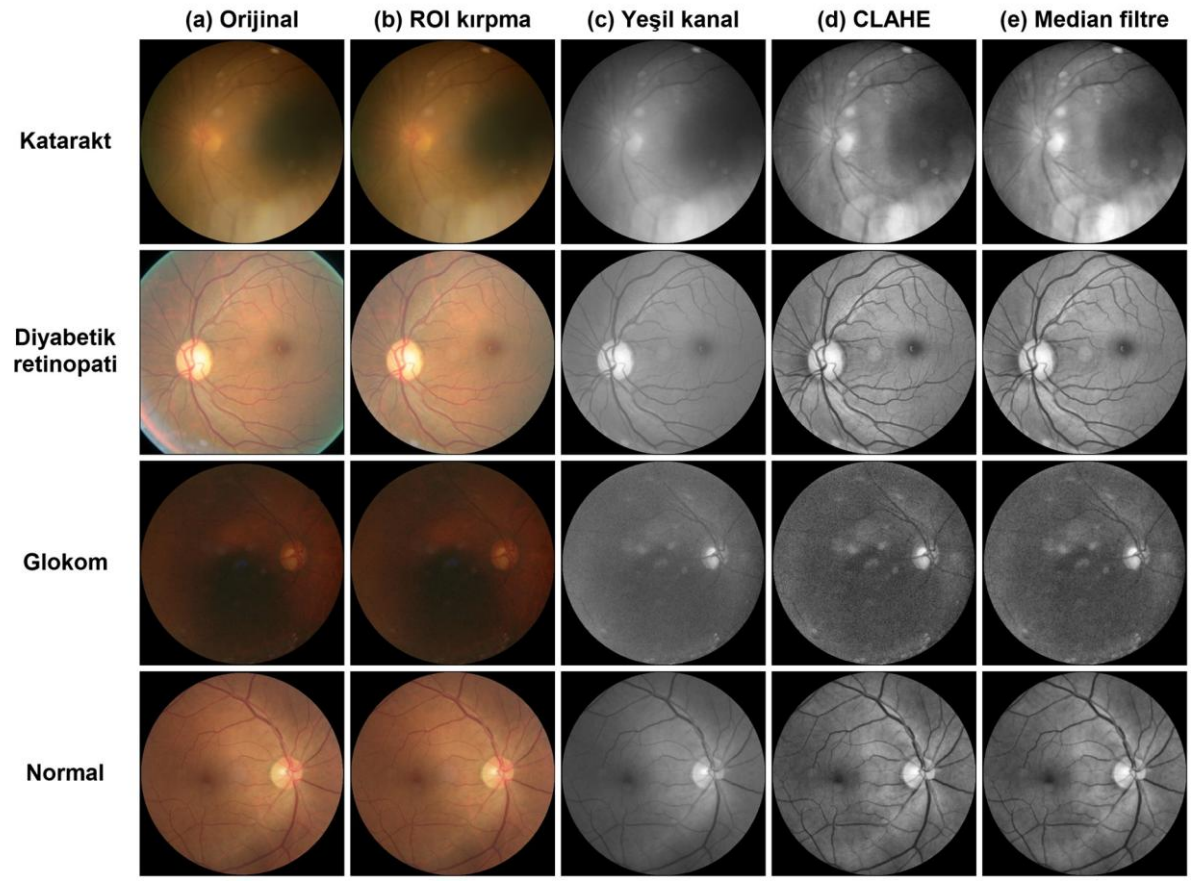
(3) Yeşil kanal: Görüntünün yeşil kanalı ayrılmıştır. Hemoglobin yeşil ışığı güçlü biçimde soğurduğundan damarlar ve kanamalar bu kanalda arka plana göre daha koyu ve belirgin görünürken kırmızı kanal genellikle doygun, mavi kanal ise karanlık ve gürültülüdür.

(4) CLAHE: Kontrast sınırlı uyarlamalı histogram eşitleme (CLAHE) [28], [29], görüntüyü 8×8 bölgeye ayırarak her bölgede ayrı histogram eşitleme uygular ve yerel kontrastı artırır. Kırpma sınırı (clipLimit = 2,0) homojen bölgelerdeki gürültünün aşırı yükseltilmesini sınırlar.

(5) Median filtre: 3×3 çekirdekli median filtre ile darbe gürültüsü azaltılmıştır. Median filtre, Gauss filtresine kıyasla damar ve lezyon kenarlarını daha iyi korur.

(6) Normalizasyon: Piksel değerleri 255'e bölünerek [0, 1] aralığına ölçeklenmiştir.

Klasik öznitelik çıkarımı bu ön işleme çıktısını ortak girdi olarak kullanmaktadır. [Kişi 4'ün teslim notuna göre güncellenecek: CNN'in girdisi bu tek kanallı çıktı mı, yoksa kırpılmış renkli görüntü mü?]



Şekil 2. Ön işleme aşamalarının her sınıftan bir örnek üzerinde gösterimi: (a) özgün görüntü, (b) ilgi bölgesi kırpma ve dairesel maske, (c) yeşil kanal, (d) CLAHE, (e) 3×3 median filtre sonrası nihai görüntü.

4.3. Anatomik Öznitelikler: Damar ve Optik Disk

[Bu bölüm Kişi 2'nin teslim notuna göre yazılacak. Planlanan içerik: yeşil kanal üzerinde black top-hat dönüşümü ya da Frangi filtresi [15] ile damar bölütleme ve damar yoğunluğu; parlaklık eşikleme ve Hough daire dönüşümü ile optik disk tespiti; optik çukurun bulunması ve çukur/disk oranının (CDR) hesaplanması [6]; yöntemin başarısız olduğu görüntülerin hata analizi. Gerekenler: kullanılan parametreler, damar haritası ve diski işaretlenmiş örnek görseller.]

4.4. Lezyon ve Netlik Öznitelikleri, Klasik Sınıflandırıcılar

[Bu bölüm Kişi 3'ün teslim notuna göre yazılacak. Planlanan içerik: sarı eksüda ve kırmızı kanama tespiti (sayı ve alan); Laplacian varyansı, kontrast ve görünür damar oranı ile netlik ölçümü; tüm özniteliklerin tek bir tabloda (oznitelikler.csv) birleştirilmesi; destek vektör makineleri (SVM) [30] ve karşılaştırma için rastgele orman (RF) [31] ile sınıflandırma; öznitelik önem analizi. Not: Laplacian varyansı çözünürlüğe bağlı olduğundan ön işleme sonrası 512×512 görüntülerde hesaplanmalıdır (bkz. 6. bölüm).]

4.5. Derin Öğrenme Modeli

[Bu bölüm Kişi 4'ün teslim notuna göre yazılacak. Planlanan içerik: ImageNet [32] üzerinde önceden eğitilmiş EfficientNet-B0 [33] ile PyTorch'ta transfer öğrenme; veri artırmada çevirme ve hafif döndürme (bulanıklık kataraktın ayırt edici ipucu olduğundan bulanıklaştırma kullanılmamıştır [9]); doğrulama kaybına göre erken durdurma ve en iyi modelin kaydedilmesi; Grad-CAM [14] ile her sınıftan doğru ve yanlış tahmin örnekleri. Gerekenler: girdi boyutu, optimizasyon algoritması, öğrenme oranı, yığın boyutu, dönem sayısı ve kayıp eğrileri.]

4.6. Değerlendirme Ölçütleri

İki yaklaşım aynı 604 görüntülük test kümesinde değerlendirilmektedir. Her k sınıfı için doğru pozitif (TP_k), yanlış pozitif (FP_k) ve yanlış negatif (FN_k) sayıları karışıklık matrisinden elde edilir. Doğruluk, sınıf başına kesinlik, duyarlılık ve F1 skoru ile makro F1 skoru Denklem (1)-(5) ile hesaplanır; burada N test görüntüsü sayısını (604), K ise sınıf sayısını (4) göstermektedir.

$$Doğruluk = \frac{\sum_{k=1}^{K} TP_k}{N} \tag{1}$$

$$Kesinlik_k = \frac{TP_k}{TP_k + FP_k} \tag{2}$$

$$Duyarlılık_k = \frac{TP_k}{TP_k + FN_k} \tag{3}$$

$$F1_k = \frac{2 \cdot Kesinlik_k \cdot Duyarlılık_k}{Kesinlik_k + Duyarlılık_k} \tag{4}$$

$$Makro\ F1 = \frac{1}{K}\sum_{k=1}^{K} F1_k \tag{5}$$

Test kümesi sınıflar arasında dengeli olduğundan (her sınıfta 151 görüntü) doğruluk, makro ortalama duyarlılığa eşittir. Hangi sınıfların birbirine karıştığını göstermek için her iki model için karışıklık matrisleri de sunulmaktadır.

4.7. Kullanıcı Arayüzü

Sistemin uygulamada nasıl kullanılabileceğini göstermek için Streamlit ile bir web arayüzü geliştirilmiştir. Kullanıcı bir fundus görüntüsü yüklediğinde arayüz sırasıyla kırpılmış ve ön işlenmiş görüntüyü, damar haritasını, seçilen modelin (CNN ya da SVM) sınıf olasılıklarını ve Grad-CAM ısı haritasını göstermekte; sonucun tıbbi tanı yerine geçmediğini belirten bir uyarı sunmaktadır. [Arayüzün son hâlinin ekran görüntüsü Kişi 5'ten alınacak.]

5. BULGULAR

[Bu bölüm Kişi 3, 4 ve 5'in sonuçları geldiğinde yazılacak.]

5.1. Klasik Yaklaşımın Sonuçları

[SVM ve RF'nin test sonuçları, karışıklık matrisleri ve öznitelik önem grafiği.]

5.2. Derin Öğrenme Modelinin Sonuçları

[EfficientNet-B0'ın eğitim ve doğrulama kayıp eğrileri, test sonuçları ve karışıklık matrisi.]

5.3. Karşılaştırma

Tablo 5. Modellerin test kümesindeki başarımı

Model	Doğruluk	Makro kesinlik	Makro duyarlılık	Makro F1
SVM	[–]	[–]	[–]	[–]
Rastgele orman	[–]	[–]	[–]	[–]
EfficientNet-B0	[–]	[–]	[–]	[–]

5.4. Grad-CAM ile Açıklanabilirlik

[Her sınıftan doğru ve yanlış tahmin edilmiş örnekler için Grad-CAM ısı haritaları ve yorumları.]

6. TARTIŞMA

[Sonuçların yorumu: hangi yaklaşımın daha başarılı olduğu, hangi sınıfların birbirine karıştığı, Grad-CAM haritalarının hangi bölgelere odaklandığı ve sonuçların literatürle (Tablo 1) karşılaştırılması sonuçlar gelince yazılacak.]

6.1. Veri Setinden Kaynaklanan Sınırlılıklar

Kaynak farklılıkları. Tablo 3'te görüldüğü gibi diyabetik retinopati ve normal sınıflarının tamamı tek bir çözünürlük ve dosya biçimindeyken 256×256 piksellik ve yüksek çözünürlüklü görüntüler yalnızca katarakt ve glokom sınıflarında bulunmaktadır. Görüntülerin 512×512 piksele getirilmesi bu farkı tamamen ortadan kaldırmaz: büyütülen 256×256 görüntüler daha yumuşak, küçültülen yüksek çözünürlüklü görüntüler ise daha keskin görünür. Derin ağların bu tür kısa yolları öğrenebildiği bilinmektedir [26]. Dolayısıyla bir modelin katarakt ve glokomu diğer sınıflardan ayırırken kısmen görüntünün kaynağına dayanması olasıdır. Bu etkinin ölçülebilmesi için test sonuçlarının Tablo 3'teki kaynak gruplarına göre ayrıca raporlanması önerilmektedir.

Çoğaltılmış görüntüler. Bölüm 3.5'te açıklanan artırılmış kopyalar nedeniyle mevcut bölmede test kümesindeki 604 görüntünün 77'sinin (%12,7) aynı özgün görüntüden üretilmiş bir kopyası eğitim kümesinde yer almaktadır. Bu oran katarakt sınıfında 40/151 (%26,5), glokom sınıfında 37/151 (%24,5) düzeyindedir. Bu görüntülerde model, test görüntüsünün döndürülmüş ya da ölçeklenmiş bir benzerini eğitim sırasında görmüş olabileceğinden bu iki sınıfa ait sonuçlar iyimser olabilir [22], [23]. Aynı sıra numarasına sahip dosyaların tek bir grup olarak aynı kümeye atanması bu sızıntıyı giderecektir.

Netlik ölçümlerinin çözünürlüğe bağlılığı. Laplacian varyansı gibi netlik ölçütleri görüntü çözünürlüğüne duyarlıdır. Ham görüntülerden her sınıf için 50 görüntüyle yapılan ön incelemede, bulanık olması beklenen katarakt sınıfı diyabetik retinopati ve glokomdan daha yüksek medyan Laplacian varyansı göstermiştir; bunun nedeni katarakt görüntülerinin büyük kısmının 256×256 piksel olmasıdır. Bu nedenle netlik öznitelikleri ön işleme sonrası aynı boyuttaki görüntüler üzerinde hesaplanmalıdır.

Etiket ve görüntü kalitesi. Veri seti farklı kaynaklardan derlendiğinden etiketler bu çalışma kapsamında bir göz hekimi tarafından yeniden doğrulanmamıştır. Örneğin normal sınıfındaki bazı görüntüler belirgin biçimde bulanıktır (Şekil 1); bu tür örnekler etiket gürültüsünden ya da düşük görüntü kalitesinden kaynaklanabilir. Ayrıca karanlık görüntülerde CLAHE, kontrastla birlikte gürültüyü de belirgin biçimde artırabilmektedir (Şekil 2, glokom örneği).

7. SONUÇ

[Sonuçlar gelince yazılacak: temel bulgular, iki yaklaşımın karşılaştırması, sınırlılıklar ve gelecek çalışmalar (kaynak gruplarına göre analiz, artırılmış kopyaların tek grupta toplanması, harici bir veri setinde doğrulama).]

KAYNAKLAR

[1] World Health Organization, "Blindness and vision impairment," *Fact sheet*, 10 Feb. 2026. [Çevrimiçi]. Erişim: https://www.who.int/news-room/fact-sheets/detail/blindness-and-visual-impairment (Erişim tarihi: 10.10.2026).

[2] GBD 2019 Blindness and Vision Impairment Collaborators and Vision Loss Expert Group of the Global Burden of Disease Study, "Causes of blindness and vision impairment in 2020 and trends over 30 years, and prevalence of avoidable blindness in relation to VISION 2020: The Right to Sight: An analysis for the Global Burden of Disease Study," *Lancet Glob. Health*, vol. 9, no. 2, pp. e144–e160, 2021, doi: 10.1016/S2214-109X(20)30489-7.

[3] Y.-C. Tham, X. Li, T. Y. Wong, H. A. Quigley, T. Aung, and C.-Y. Cheng, "Global prevalence of glaucoma and projections of glaucoma burden through 2040: A systematic review and meta-analysis," *Ophthalmology*, vol. 121, no. 11, pp. 2081–2090, 2014, doi: 10.1016/j.ophtha.2014.05.013.

[4] Z. L. Teo et al., "Global prevalence of diabetic retinopathy and projection of burden through 2045: Systematic review and meta-analysis," *Ophthalmology*, vol. 128, no. 11, pp. 1580–1591, 2021, doi: 10.1016/j.ophtha.2021.04.027.

[5] H. Pratt, F. Coenen, D. M. Broadbent, S. P. Harding, and Y. Zheng, "Convolutional neural networks for diabetic retinopathy," *Procedia Comput. Sci.*, vol. 90, pp. 200–205, 2016, doi: 10.1016/j.procs.2016.07.014.

[6] J. Cheng et al., "Superpixel classification based optic disc and optic cup segmentation for glaucoma screening," *IEEE Trans. Med. Imaging*, vol. 32, no. 6, pp. 1019–1032, 2013, doi: 10.1109/TMI.2013.2247770.

[7] Z. Li, Y. He, S. Keel, W. Meng, R. T. Chang, and M. He, "Efficacy of a deep learning system for detecting glaucomatous optic neuropathy based on color fundus photographs," *Ophthalmology*, vol. 125, no. 8, pp. 1199–1206, 2018, doi: 10.1016/j.ophtha.2018.01.023.

[8] J. N. Kirkpatrick, A. Manivannan, A. K. Gupta, J. Hipwell, J. V. Forrester, and P. F. Sharp, "Fundus imaging in patients with cataract: Role for a variable wavelength scanning laser ophthalmoscope," *Br. J. Ophthalmol.*, vol. 79, no. 10, pp. 892–899, 1995, doi: 10.1136/bjo.79.10.892.

[9] A. B. Crane, H. S. Choudhry, and M. H. Dastjerdi, "Effect of simulated cataract on the accuracy of artificial intelligence in detecting diabetic retinopathy in color fundus photos," *Indian J. Ophthalmol.*, vol. 72, suppl. 1, pp. S42–S45, 2024, doi: 10.4103/IJO.IJO_1163_23.

[10] N. Li, T. Li, C. Hu, K. Wang, and H. Kang, "A benchmark of ocular disease intelligent recognition: One shot for multi-disease detection," in *Benchmarking, Measuring, and Optimizing*, ser. Lecture Notes in Computer Science. Cham, Switzerland: Springer, 2021, pp. 177–193, doi: 10.1007/978-3-030-71058-3_11.

[11] T. Walter, J.-C. Klein, P. Massin, and A. Erginay, "A contribution of image processing to the diagnosis of diabetic retinopathy—Detection of exudates in color fundus images of the human retina," *IEEE Trans. Med. Imaging*, vol. 21, no. 10, pp. 1236–1243, 2002, doi: 10.1109/TMI.2002.806290.

[12] V. Gulshan et al., "Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs," *JAMA*, vol. 316, no. 22, pp. 2402–2410, 2016, doi: 10.1001/jama.2016.17216.

[13] D. S. W. Ting et al., "Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes," *JAMA*, vol. 318, no. 22, pp. 2211–2223, 2017, doi: 10.1001/jama.2017.18152.

[14] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2017, pp. 618–626, doi: 10.1109/ICCV.2017.74.

[15] A. F. Frangi, W. J. Niessen, K. L. Vincken, and M. A. Viergever, “Multiscale vessel enhancement filtering,” in *Medical Image Computing and Computer-Assisted Intervention — MICCAI’98*, ser. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer, 1998, pp. 130–137, doi: 10.1007/BFb0056195.

[16] A. Budai, R. Bock, A. Maier, J. Hornegger, and G. Michelson, “Robust vessel segmentation in fundus images,” *Int. J. Biomed. Imaging*, vol. 2013, Art. no. 154860, 2013, doi: 10.1155/2013/154860.

[17] M. S. Junayed, M. B. Islam, A. Sadeghzadeh, and S. Rahman, “CataractNet: An automated cataract detection system using deep learning for fundus images,” *IEEE Access*, vol. 9, pp. 128799–128808, 2021, doi: 10.1109/ACCESS.2021.3112938.

[18] T. Babaqi, M. Jaradat, A. E. Yildirim, S. H. Al-Nimer, and D. Won, “Eye disease classification using deep learning techniques,” arXiv:2307.10501, 2023, doi: 10.48550/arXiv.2307.10501.

[19] R. Alsohemi and S. Dardouri, “Fundus image-based eye disease detection using EfficientNetB3 architecture,” *J. Imaging*, vol. 11, no. 8, Art. no. 279, 2025, doi: 10.3390/jimaging11080279.

[20] E. S. Cutur and N. G. Inan, “Multi-class classification of retinal eye diseases from ophthalmoscopy images using transfer learning-based vision transformers,” *J. Imaging Inform. Med.*, vol. 38, no. 5, pp. 3110–3124, 2025, doi: 10.1007/s10278-025-01416-7.

[21] E. Acevedo, D. Orantes, M. Acevedo, and R. Carreño, “Identification of eye diseases through deep learning,” *Diagnostics*, vol. 15, no. 7, Art. no. 916, 2025, doi: 10.3390/diagnostics15070916.

[22] E. Yagis et al., “Effect of data leakage in brain MRI classification using 2D convolutional neural networks,” *Sci. Rep.*, vol. 11, Art. no. 22544, 2021, doi: 10.1038/s41598-021-01681-w.

[23] S. Kapoor and A. Narayanan, “Leakage and the reproducibility crisis in machine-learning-based science,” *Patterns*, vol. 4, no. 9, Art. no. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[24] G. V. Doddi, “eye_diseases_classification,” Kaggle, 2022. [Çevrimiçi]. Erişim: https://www.kaggle.com/datasets/gunavenkatdoddi/eye-diseases-classification (Erişim tarihi: 10.10.2026).

[25] P. Porwal et al., “Indian diabetic retinopathy image dataset (IDRiD): A database for diabetic retinopathy screening research,” *Data*, vol. 3, no. 3, Art. no. 25, 2018, doi: 10.3390/data3030025.

[26] R. Geirhos et al., “Shortcut learning in deep neural networks,” *Nat. Mach. Intell.*, vol. 2, no. 11, pp. 665–673, 2020, doi: 10.1038/s42256-020-00257-z.

[27] Keras Team, “keras-preprocessing: image/iterator.py,” GitHub. [Çevrimiçi]. Erişim: https://github.com/keras-team/keras-preprocessing/blob/master/keras_preprocessing/image/iterator.py (Erişim tarihi: 10.10.2026).

[28] S. M. Pizer et al., “Adaptive histogram equalization and its variations,” *Comput. Vis. Graph. Image Process.*, vol. 39, no. 3, pp. 355–368, 1987, doi: 10.1016/S0734-189X(87)80186-X.

[29] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” in *Graphics Gems IV*, P. S. Heckbert, Ed. San Diego, CA, USA: Academic Press, 1994, pp. 474–485, doi: 10.1016/B978-0-12-336156-1.50061-6.

[30] C. Cortes and V. Vapnik, “Support-vector networks,” *Mach. Learn.*, vol. 20, no. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018.

[31] L. Breiman, “Random forests,” *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[32] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A large-scale hierarchical image database,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2009, pp. 248–255, doi: 10.1109/CVPR.2009.5206848.

[33] M. Tan and Q. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. 36th Int. Conf. Mach. Learn. (ICML)*, ser. Proceedings of Machine Learning Research, vol. 97, 2019, pp. 6105–6114.